Linked Open Data: Computerlinguistische Resourcen und Werkzeuge im WWW

Seminar im Modul M-GSW-10 SoSe 2018

Prof. Dr. Udo Hahn


Lehrstuhl für Angewandte Germanistische Sprachwissenschaft / Computerlinguistik

Institut für Germanistische Sprachwissenschaft Friedrich-Schiller-Universität Jena

http://www.julielab.de


Allgemeine Hinweise

- Termin: Do, 16-18h (Johannisfr.hof 3, SR 2)
- Materialien im Netz
 - http://www.julielab.de
 "Students"
- Sprechstunde: Mi, 12-13h (bA) (FG 30, R 004)
- © Email: udo.hahn@uni-jena.de
- Fachliteratur: durchgängig in Englisch




Linking Open Data Cloud

http://lod-cloud.net/




Today's knowledge bases

> 60 Bio. subject-predicate-object triples from > 1000 sources



Idee

- WWW = Netz von Webseiten
- <u>• LOD = Netz von (inhaltlichen) Daten</u>
 - -> Datenintegration & höhere Datenqualität



Technische Rahmenbedingungen von LOD

- Linked Open Data (LOD)
 - Im WWW frei verfügbare Datenbestände
 - Identifikation durch Uniform Resource Identifier (URI)
 - Abruf per HTTP
 - Kodierung der Daten via Resource Description Framework (RDF)
 - und darauf aufbauende Standards wie SPARQL und die Web Ontology Language (OWL)

Tim Berners-Lee Credo

- 1. Use URIs as names for things
- 2. Use HTTP URIs so that people can look up those names.
- 3. When someone looks up a URI, provide useful information, using the standards (RDF, SPARQL)
- 4. Include links to other URIs, so that they can discover more things.

URI

Uniform Resource Identifier (URI)

"Ein Uniform Resource Identifier (URI) ist eine kompakte Reihenfolge von Zeichen, die eine abstrakte oder physische Quelle bezeichnet."

ISA's 10 Rules for Persistent URIs

Ein Land, z.B. Belgien

http://publications.europa.eu/resource/authority/country/BEL



http://publications.europa.eu/resource/authority/corporate-body/PUBL



http://publications.europa.eu/resource/authority/country/





RDF, SPARQL

RDF & SPARQL

Das **Resource Description Framework** (RDF) ist eine Syntax, um Daten und Ressourcen im Web darzustellen.

RDF gliedert jede Information in **Triples**:

- Subjekt
 – eine Quelle, die mit einer URI identifiziert werden kann.
- Prädikat eine URI-identifizierte wiederverwendete Besonderheit einer Beziehung.
- Objekt eine Ressource oder Symbol, mit dem das Thema verwandt ist.

http://dbpedia.org/resource/Brussels ist die Hauptstadt von "Belgien".
OR
http://dbpedia.org/resource/Brussels ist die Hauptstadt von http://dbpedia.org/resource/Belgium.

Subjekt

Prädikat

Objekt

SPARQL ist eine standardisierte Sprache, um RDF-Daten abzufragen.

Rolle der Computerlinguistik im Rahmen von LOD


- CL: "ressource-heavy"
 - GROSSE Korpora (> 1 Mio. Texte, > 100 Mio. Tokens, Giga/Terabyte-Skala)
 - GROSSE Lexika (> 100k Einträge)
 - GROSSE Wissensbasen (> 10-100 Mio. Items)
- Resourcen im World Wide Web als Grundlage für die computerlinguistische Nutzung
- Aufbau von LOD-Resourcen durch Verfahren der Computerlinguistik

Beispiel 1

- Europeana
 - Multimediale, multilinguale Digital Library zu europäischem Kulturerbe
 - 27 Mio Bilder, 22 Mio Texte, 1, 1 Mio Videos, 700k Audios,
 - https://www.europeana.eu/portal/de

Europeana

http://www.europeana.eu/portal/






Linked Open Data Beispiel 2

Wikipedia

- Mehrsprachige Online Enzyklopädie
- Ca. 40 Mio Artikel (2,17 Mio. in Deutsch)
- · Ca. 300 Sprachen



Beispiel 3

- Wiktionary
 - Wörterbuch-Pendant zu Wikipedia
 - Mehrsprachiges Wörterbuch/Thesaurus
 - 23,6 Mio Einträge
 - 172 Sprachen



Beispiel 4

- Wikipedia

 Dbpedia (U MA, U L, HPI)
 - Semi-strukturierte Daten (Tabellen) und Fließtext aus Wikipedia werden mit computerlinguistischen Verfahren automatisch überführt in vollständig struktrierte Daten
 - · Dbpedia (2014): 4,6 Mio. Datensätze, 3 Mrd. Fakten
 - Multilinguale Wikipedia (EN, DE, FR, ES, IT, ...)
 - Verlinkt mit Freebase, Open Cyc, UMBEL, GeoNames, MusicBrainz, CIA World Factbook, New York Times [LOD], Digital Bibliography & Library Project, Project Gutenberg, Jamendo, Eurostat US-Census
 - Datenrepräsentation: RDF

Search Wikipedia

Read View source View history

Ein Wikipedia-Eintrag

Article Talk



Main page Contents Featured content Current events Random article Donate to Wikipedia Wikipedia store

Interaction

Help
About Wikipedia
Community portal
Recent changes
Contact page

Tools

What links here Related changes Upload file Special pages Permanent link Page information

Milsidata itam

Tim Berners-Lee

From Wikipedia, the free encyclopedia

Sir Timothy John Berners-Lee OM KBE FRS FREng FRSA FBCS (born 8 June 1955),^[1] also known as **TimBL**, is an English engineer and computer scientist, best known as the inventor of the World Wide Web. He is currently a professor of Computer Science at the University of Oxford.^[3] He made a proposal for an information management system in March 1989,^[4] and he implemented the first successful communication between a Hypertext Transfer Protocol (HTTP) client and server via the internet in mid-November the same year.^{[5][6][7][8][9]}

Berners-Lee is the director of the World Wide Web Consortium (W3C), which oversees the continued development of the Web. He is also the founder of the World Wide Web Foundation and is a senior researcher and holder of the founders chair at the MIT Computer Science and Artificial Intelligence Laboratory (CSAIL).^[10] He is a director of the Web Science Research Initiative (WSRI),^[11] and a member of the advisory board of the MIT Center for Collective Intelligence.^{[12][13]} In 2011, he was named as a member of the board of trustees of the Ford Foundation.^[14] He is a founder and president of the Open Data Institute.

In 2004, Berners-Lee was knighted by Queen Elizabeth II for his pioneering work. [15][16] In April 2009, he was elected a foreign associate of the United States National Academy of Sciences. [17][18] Named in *Time* magazine's list of the 100 Most Important People of the 20th century, Berners-Lee has received a number of other accolades for his invention. [19] He was honoured as the "Inventor of the World Wide Web" during the 2012 Summer Olympics opening ceremony, in which he appeared in person, working with a vintage NeXT Computer at the London Olympic Stadium. [20] He tweeted "This is for everyone", [21] which instantly was spelled out in LCD lights attached to the chairs of the 80,000 people in the audience. [20] Berners-Lee received the 2016 Turing Award "for inventing the World Wide Web, the first web browser, and the fundamental protocols and algorithms allowing the Web to scale". [22]

Solutions Not logged in Talk Contributions Create account Log in

Q

Sir
Tim Berners-Lee
OM KBE FRS FREng FRSA FBCS




Berners-Lee in 2014

Born

Timothy John Berners-Lee 8 June 1955 (age 62)^[1] London, England

Not logged in Talk Contributions Create account Log in

Ein Wikipedia-Eintrag und seine Dbpedia-Form



Tools
What links here
Related changes
Upload file
Special pages
Permanent link

Page information

In 2004, Berners-Lee was knighted by Queen Elizabeth II for his pioneering work. [15][19] In April 2009, he was elected a foreign associate of the United States National Academy of Sciences. [17][18] Named in *Time* magazine's list of the 100 Most Important People of the 20th century, Berners-Lee has received a number of other accolades for his invention. [19] He was honoured as the "Inventor of the World Wide Web" during the 2012 Summer Olympics opening ceremony, in which he appeared in person, working with a vintage NeXT Computer at the London Olympic Stadium. [20] He tweeted "This is for everyone", [21] which instantly was spelled out in LCD lights attached to the chairs of the 80,000 people in the audience. [20] Berners-Lee received the 2016 Turing Award "for inventing the World Wide Web, the first web browser, and the fundamental protocols and algorithms allowing the Web to scale", [22]




Berners-Lee in 2014

Born

Timothy John Berners-Lee 8 June 1955 (age 62)^[1] London, England

Datenquellen von DBpedia





Beispiel 5

- Wikipedia → YAGO (MPI SB)
 - Automatisch aus Wikipedia erzeugte Ontologie und Wissensbasis (computerlinguistische Methodik)
 - Unter Verwendung von Geonames, WordNet
 - Links zu Dbpedia und SUMO ontology
 - 10 Mio. Einträge und 120 Mio. Fakten
 - https://www.mpi-inf.mpg.de/departments/databases-and-informationsystems/research/yago-naga/yago/

Themen

- Repräsentationsaspekte und technischer Hintergrund zu LOD
 - RDF, URI, SPARQL, SKOS, OWL, HTTP ... Triple-Stores
- Textresourcen
 - · Wikipedia, Europeana, Projekt Gutenberg, ...
- Sprachresourcen (Lexika)
 - Wiktionary, WordNet, LemonUBY, ...
- Computerlinguistische Anwendungen
 - Wikipedia → DBpedia
 - Wikipedia → YAGO

Seminarleistungen

- Vortrag (mündlich)
 - 1-stündig
 - Elektronische Version (PDF, PPT) verfügbar machen
- Referat (schriftlich)
 - 15-20 Seiten Kerntext (mit Standardformaten)
 - Elektronische Version (PDF, DOC) verfügbar machen
 - Eidesstattliche Erklärung zur Eigenautorenschaft
 - Wir prüfen mit Plagiatserkennungs-Software
 - Abgabe: Anfang Juli 2018

Bemerkungen zu Referaten

• Aufbaumuster:

- Deck- bzw. Titelblatt mit vollständigen Angaben
- Inhaltsverzeichnis
- Einführung ins Thema, Motivation
- Themenabhandlung: grundlegende Formalisierungen, Verfahrensbeschreibungen (Algorithmen), Systemfunktionalitäten, Ressourcenmerkmale, Experimente/Evaluationen usw.
- Fazit mit kritischer Würdigung, offene Probleme ansprechen
- Bibliographie

• Zitationen:

- Alle verwendeten Quellen zitieren
 - Mit einem bibliographisch korrektem Zitat die jeweilige Quelle eindeutig beschreiben
 - Fachartikel <u>nicht</u> mit http://...foo.pdf-Link zitieren
 - Online-Quellen mit URLs und Datum des letztem Zugriffs
- Wikipedia ist keine zitierfähige wissenschaftliche Quelle!
- Eigenleistungen (Literatur, Beschäftigung mit konkreten Ressourcen/Systemen usw.) sind sehr erwünscht→unabdingbar!

Wege zum Vortrag und Referat

- Email: Anmeldung von drei nach fallender
 Priorität geordneten Themenwünschen
 - First-come, first-served
- Email: Themenvergabe durch Dozenten
- Erste Literaturhinweise als "Saat" nach Bestätigung der Themenauswahl
- Themenbearbeitung durch Referenten
 - Mündlicher Vortrag zum vereinbarten Termin
 - Schriftliches Referat (unter Einhaltung der organisatorischen Verabredungen) zum vereinbarten Termin

Online-Tutorials

- Felix Ostrowski; Pascal Christoph: Einführung in Linked Open Data (2011)
 - http://swib.org/swibll/vortraege/swibll-felixostrowski.pdf

Wichtige Zeitschriften

- Journal of Web Semantics: Science, Services and Agents on the World Wide Web
- Semantic Web Interoperability, Usability,
 Applicability

Wichtige Konferenzen

 Proceedings of the 6th Workshop on Linked Data in Linguistics: Towards Linked Data Science @ LREC 2018 [und frühere Workshops; üblich: 2-jährlich mit LREC]

 LREC 2018 – Proceedings of the 11th International Conference on Language Resources and Evaluation [und frühere Konferenzen, 2-jährlich: 2016, 2014, ...]

The Semantic Web. Proceédings of the 17th International Semantic Web Conference – ISWC 2018 [und frühere Konferenzen; jährlich]

WWW '18 – Proceedings of the 27th International Conference on World Wide Web [und frühere Konferenzen; jährlich]

 The Semantic Web: Proceedings of the 15th European Semantic Web Conference – ESWC 2018 [und frühere Konferenzen; jährlich]

Ablaufplan

```
12.4. Hahn
19.4. ---
26.4. ---
03.5. Hahn – Themenvergabe
10.5. ---
17.5. ---
24.5. ---
31.5. Gesprächstermin
07.6. Gesprächstermin
14.6. ---
21.6. ---
28.6. --- (Retreat)
05.7. Patrick Zerrer
```

12.7. Natalia Sulaberidze

Sprachressourcen: Lexika Textressourcen:

Wikipedia, Europeana