#### Computerlinguistik I

Vorlesung im WiSe 2018/2019 (M-GSW-09)

Prof. Dr. Udo Hahn

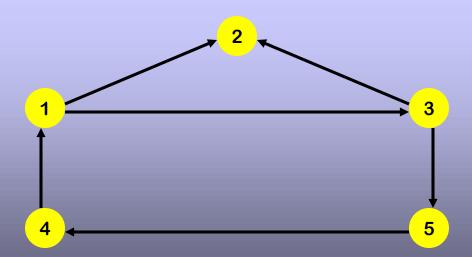
Lehrstuhl für Computerlinguistik
Institut für Germanistische Sprachwissenschaft
Friedrich-Schiller-Universität Jena

http://www.julielab.de

- Ein endlicher gerichteter Graph ist ein Paar  $\Gamma = (\mathcal{K}, \rho)$ , wobei
  - $-\mathcal{K}$  endliche Menge von Knoten
  - $\rho \subseteq \mathcal{K} \times \mathcal{K}$  endliche Menge von Kanten

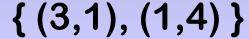
#### Beispiel für einen Graphen

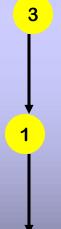
$$\Gamma = (\{1, 2, 3, 4, 5\}, \{(1,2), (1,3), (3,2), (3,5), (4,1), (5,4)\})$$



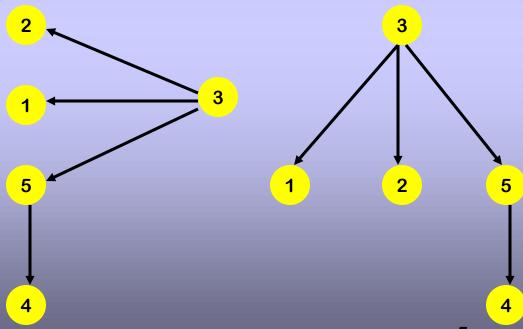
- Ein (endlicher) Baum ist ein endlicher gerichteter Graph  $\Gamma$  = ( $\mathcal{K}$ ,  $\rho$ ), wobei
  - $\mathcal{K}$  enthält genau einen Knoten  $k_{\rm w}$  (die sog. Wurzel) mit der Eigenschaft, dass für jede Kante  $(k,k')\in\rho$  gilt:  $k_{\rm w}\neq k'$ ;
  - Zu jedem Knoten  $k \neq k_w$  gibt es genau eine Folge von Knoten  $k_w = k_0$ ,  $k_1$ ,  $k_2$ , ...,  $k_n = k$ ,  $n \ge 1$ , mit  $(k_i, k_{i+1}) \in \rho$  für  $0 \le i \le n-1$ .

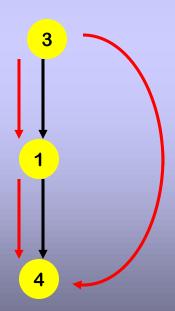
#### Beispiele für Bäume

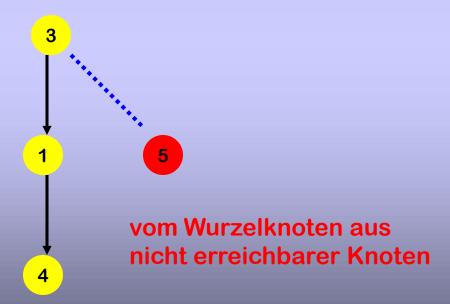




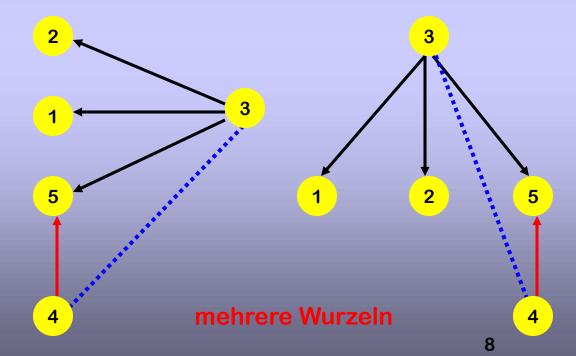
$$\{(3,1), (3,2), (3,5), (5,4)\}$$



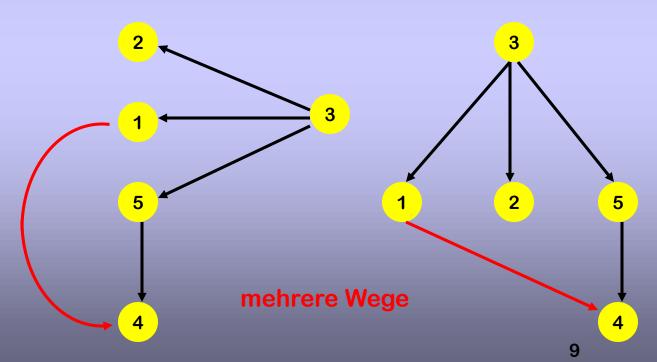




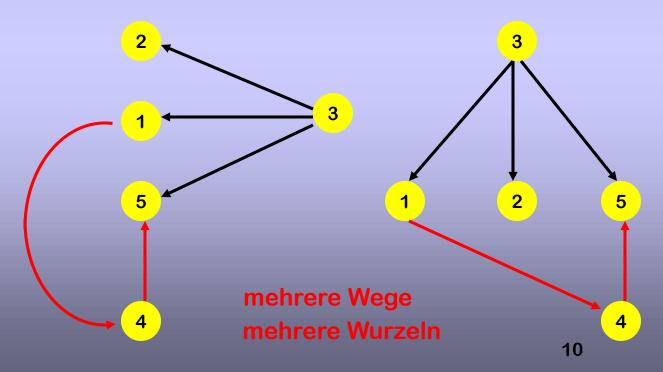
$$\{(3,1), (3,2), (3,5), (4,5)\}$$



$$\{(3,1), (3,2), (3,5), (5,4), (1,4)\}$$



$$\{(3,1), (3,2), (3,5), (4,5), (1,4)\}$$

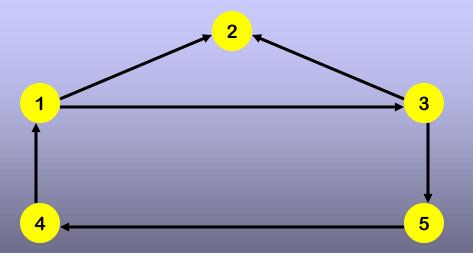


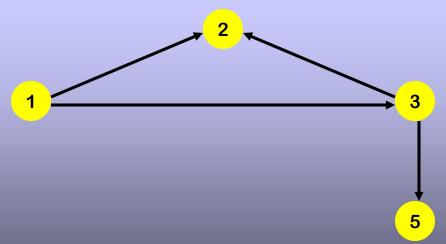
- Eine Folge  $k_0$ ,  $k_1$ ,  $k_2$ , ...,  $k_n$ ,  $n \ge 0$ , von Knoten mit  $(k_i, k_{i+1}) \in \rho$  für  $0 \le i \le n-1$  heißt Pfad der Länge n von  $k_0$  nach  $k_n$ .
- Sei  $(k,k') \in \rho$ , dann heißt k' direkter Nachfolger von k und k direkter Vorgänger von k'. Wenn k und k' Knoten sind, für die ein Pfad von k' nach k' existiert, dann heißt k' Nachfolger von k' bzw. k' Vorgänger von k'.
- Ein Knoten k, der keinen Nachfolger hat, heißt Endknoten (oder Blatt).

• Sei  $\Gamma$  = ( $\mathcal{K}$ ,  $\rho$ ) ein endlicher gerichteter ter Graph. Ein endlicher gerichteter Graph  $\Gamma^*$  = ( $\mathcal{K}^*$ ,  $\rho^*$ ) mit  $\mathcal{K}^* \subseteq \mathcal{K}$  und  $\rho^* \subseteq \rho \cap \mathcal{K}^*$  x  $\mathcal{K}^*$  heißt Teilgraph von  $\Gamma$ .

$$\Gamma = (\{1, 2, 3, 4, 5\}, \{(1,2), (1,3), (3,2), (3,5), (4,1), (5,4)\})$$

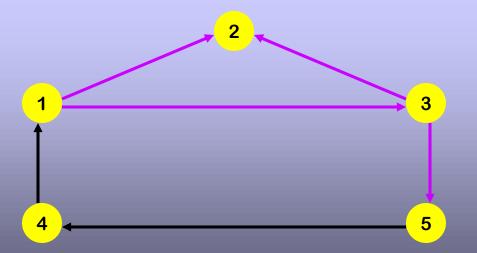
$$\Gamma^* = ( \{1, 2, 3, 5\},$$
2),  $\{ (1,2), (1,3), (3,2),$ 
4) \})  $(3,5) \}$ )

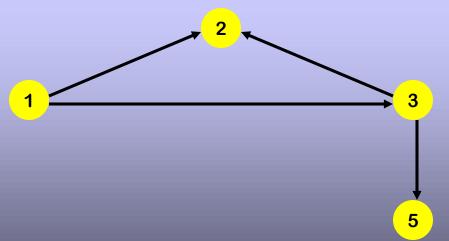




$$\Gamma = (\{1, 2, 3, 4, 5\}, \{(1,2), (1,3), (3,2), (3,5), (4,1), (5,4)\})$$

$$\Gamma^* = ( \{1, 2, 3, 5\}, \\ 2), \qquad \{ (1,2), (1,3), (3,2), \\ 4) \} ) \qquad (3,5) \} )$$

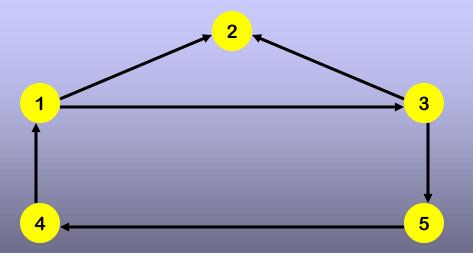




$$\Gamma = (\{1, 2, 3, 4, 5\}, \Gamma^* = (\{1, 3, 5\}, \{(1,2), (1,3), (3,2), \{(1,3), (3,5)\})$$

$$(3,5), (4,1), (5,4)\})$$

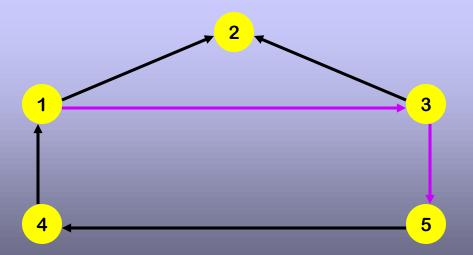
$$\Gamma^* = (\{1, 3, 5\}, \{(1,3), (3,5)\})$$





$$\Gamma = (\{1, 2, 3, 4, 5\}, \{(1,2), (1,3), (3,2), (3,5), (4,1), (5,4)\})$$

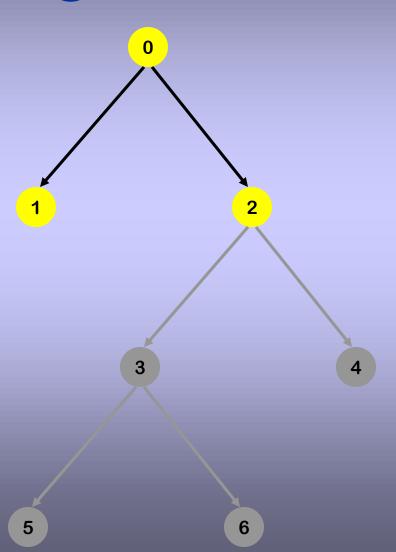
$$\Gamma^* = (\{1, 3, 5\}, \{(1,3), (3,5)\})$$

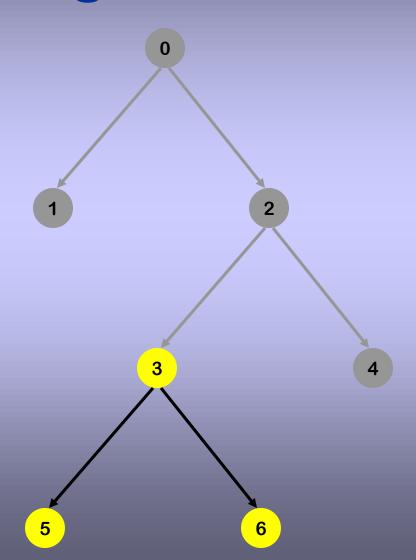




- Sei  $\Gamma$  ein Baum. Ein Teilgraph  $\Gamma^*$  von  $\Gamma$ , der selbst wieder ein Baum ist, heißt Teilbaum von  $\Gamma$ .
  - $\Gamma^*$  heißt Anfangsteilbaum von  $\Gamma$ , wenn  $\Gamma^*$  und  $\Gamma$  dieselbe Wurzel haben.
  - $\Gamma^*$  heißt Endteilbaum von  $\Gamma$ , wenn alle Endknoten von  $\Gamma^*$  auch Endknoten in  $\Gamma$  sind.

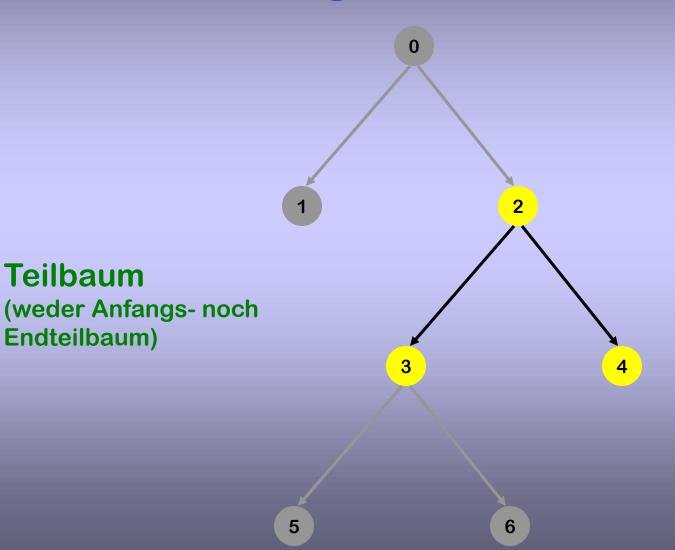
Anfangsteilbaum





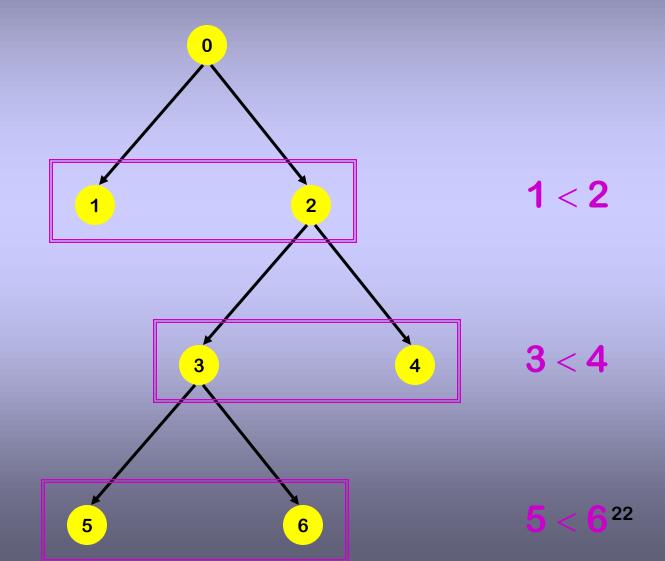
**Endteilbaum** 

20

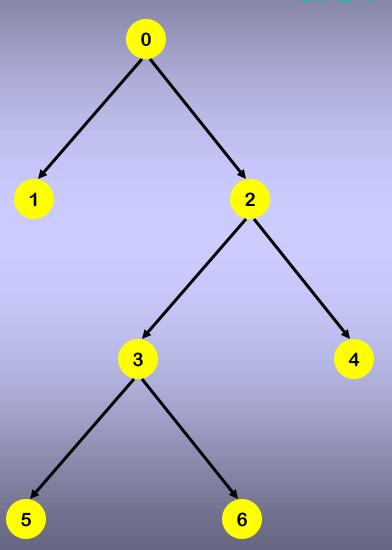


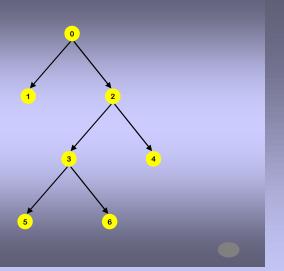
• Ein partiell geordneter Baum ist ein Tripel  $\Gamma$  = ( $\mathcal{K}$ ,  $\rho$ , <), wobei "<" eine partielle Ordnung (transitiv, irreflexiv) auf  $\mathcal{K}$  ist, die für jeden Knoten die Menge seiner direkten Nachfolger linear ordnet und auch nur solche Knoten in Bezug zueinander setzt, die direkte Nachfolger ein und desselben Vorgängerknotens sind.

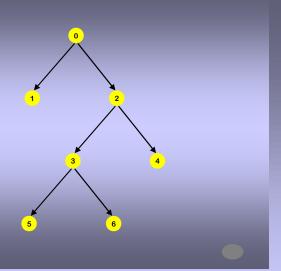
### (Partiell) geordneter Baum

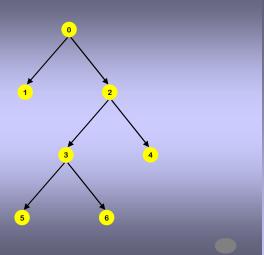


- Ein vollständig geordneter Baum ist ein Tripel  $\Gamma = (\mathcal{K}, \rho, <^*)$ , wobei "<" eine vollständige Ordnung auf  $\mathcal{K}$  ist , die aus der partiellen Ordnung "<" durch folgende Vereinbarung aufgebaut wird. Seien k,  $k_1$  und  $k_2$  Knoten aus  $\mathcal{K}$ . Dann gilt:  $k_1 <^* k_2$  (gesprochen: "  $k_1$  ist vor | links von  $k_2$ "), falls:
  - $-k_1 < k_2$  oder
  - $k_1$  ist Nachfolger von  $k_2$  oder
  - $k_1$  ist Nachfolger von k' und  $k' < k_2$  oder
  - $k_2$  ist Nachfolger von k' und  $k_1 < k'$ .

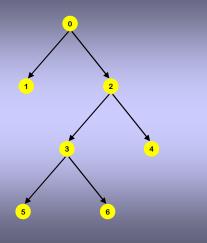




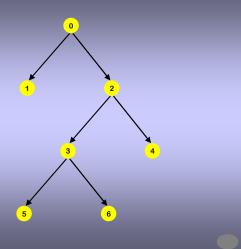


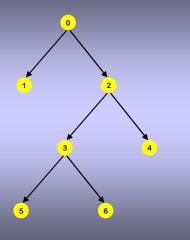


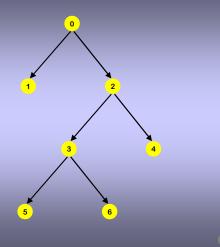
$$6 < ^* 0$$



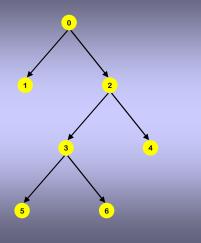
$$6 < ^* 0$$

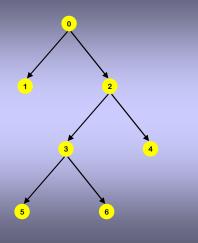


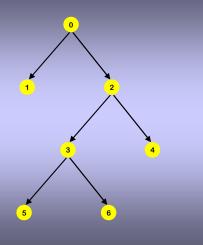


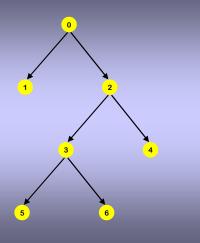


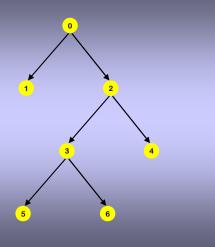
$$6 < ^* 0$$



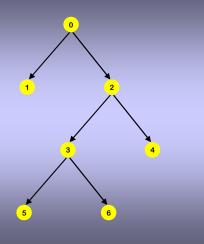


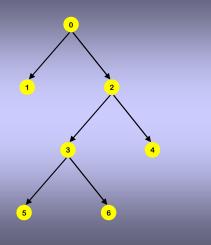




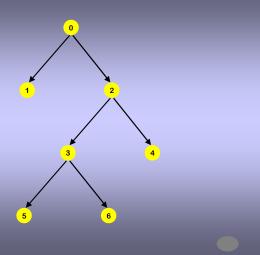


## Berechnung der Relation <\*

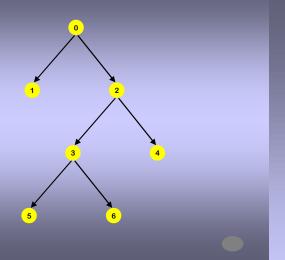




## Berechnung der Relation <\*

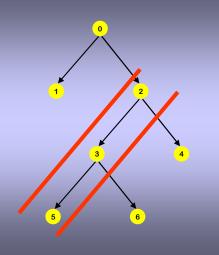




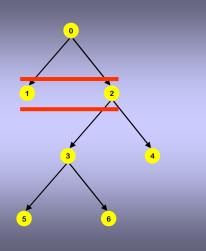


## Berechnung der Relation <\*

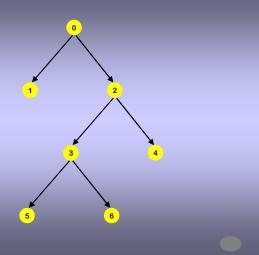
 $\overline{k_2}$  ist Nachfolger von  $\overline{k}$  und  $\overline{k_1} < \overline{k}$ 



 $k_2$  ist Nachfolger von k' und  $k_1 < k'$ 



 $k_2$  ist Nachfolger von k' und

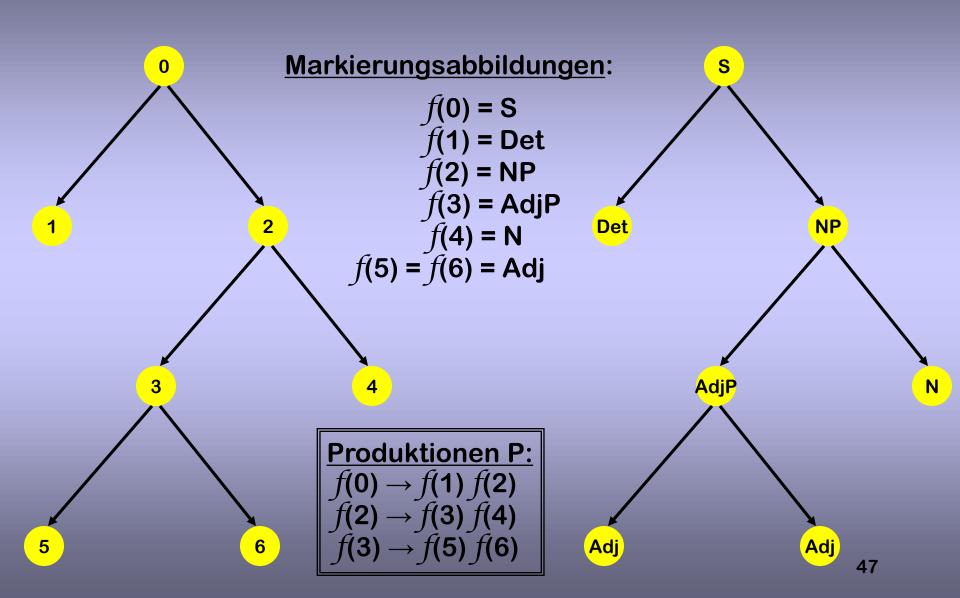


### Grundbegriffe zu Ableitungsbäumen

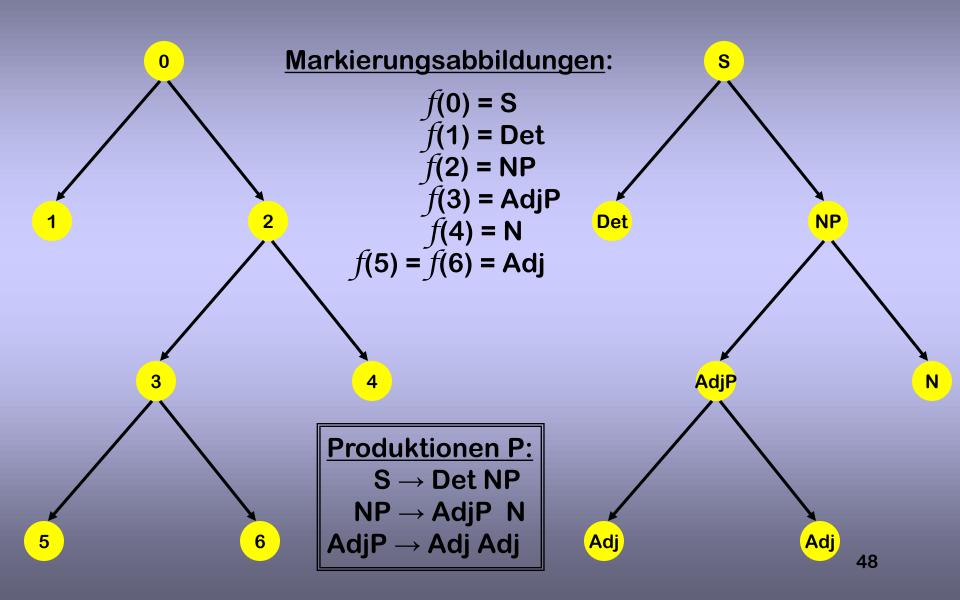
 Ein vollständig geordneter, markierter Baum ist ein 4-Tupel  $\Gamma = (\mathcal{K}, \rho, <^*, f), \text{ wobei } (\mathcal{K}, \rho, <^*)$ ein vollständig geordneter Baum und  $f: \mathcal{K} \rightarrow \mathcal{M}$  eine Abbildung von Knoten  $\mathcal K$  in die Menge  $\mathcal M$ der sog. Markierungen (Marken, Etiketten) ist.

# Grundbegriffe zu Ableitungsbäumen

- Sei G = ( N, T, P, S ) eine kontextfreie Grammatik. Ein vollständig geordneter, markierter Baum  $\Gamma$  = (  $\mathcal{K}$ ,  $\rho$ , <\*, f ) heißt Ableitungsbaum zu G, wenn gilt:
  - f bildet die Knotenmenge  $\mathcal{K}$  auf  $\mathcal{M}$  = N  $\cup$  T  $\cup$  { $\varepsilon$ } ab;
  - für die Wurzel  $k_w$  von Γ gilt:  $f(k_w)$  ∈ N;
  - Ist k ∈  $\mathcal{K}$  und {k<sub>1</sub>, k<sub>2</sub>, ..., k<sub>r</sub>} die Menge aller seiner direkten Nachfolger mit k<sub>i</sub> < k<sub>i+1</sub> für 1≤i<r, so ist  $f(k) \rightarrow f(k_1) f(k_2) ... f(k_r)$  eine Produktion in P.
- Im Fall  $f(k_w)$  = S heißt der Ableitungsbaum auch Strukturbaum zu G.

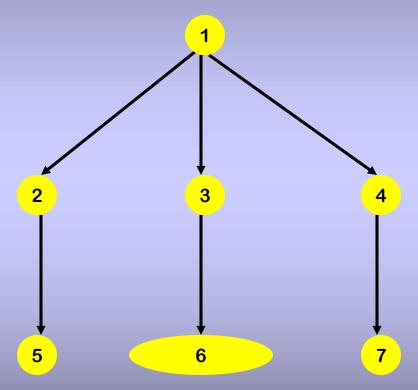


#### Strukturbaum

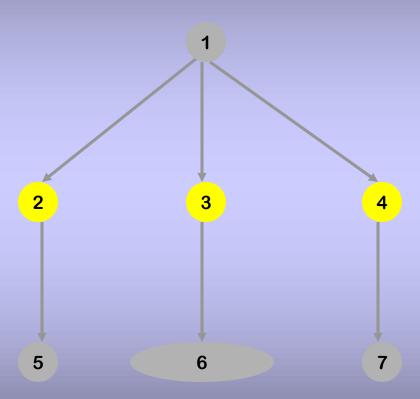


### Grundbegriffe zu Ableitungsbäumen

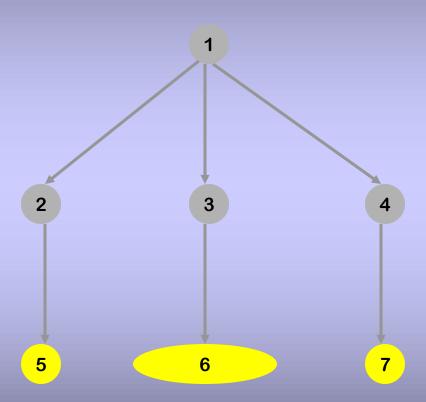
- Sei  $\Gamma$  = ( $\mathcal{K}$ ,  $\rho$ ) ein Baum. Eine Teilmenge  $C \subseteq \mathcal{K}$  heißt Schnitt in  $\Gamma$ , wenn gilt:
  - 1. es gibt keinen Pfad in  $\Gamma$ , der zwei verschiedene Knoten aus C enthält;
  - 2. für jede Teilmenge  $\mathcal{K}^* \subseteq \mathcal{K}$ , die  $\mathcal{C}$  echt umfasst (also:  $\mathcal{C} \subset \mathcal{K}^* \subseteq \mathcal{K}$ ), ist Forderung (1) verletzt.



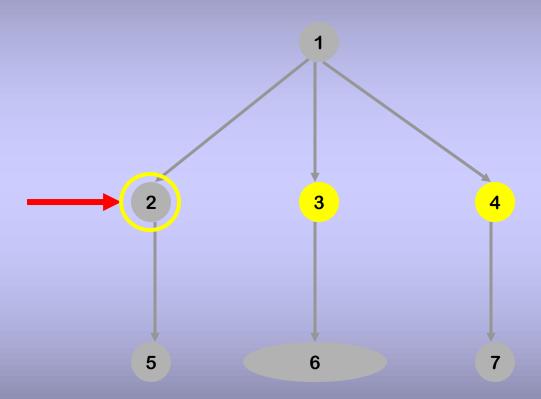
#### Schnitt



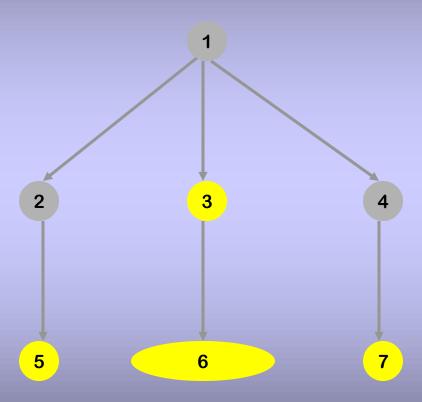
#### Schnitt



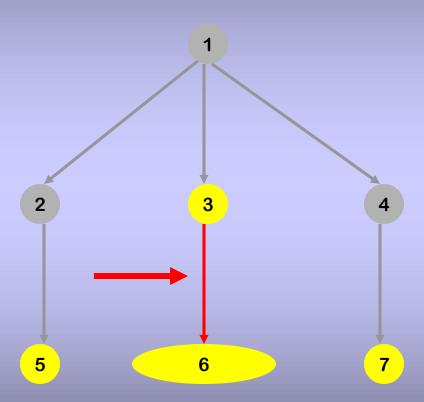
#### **Kein Schnitt**



#### **Kein Schnitt**



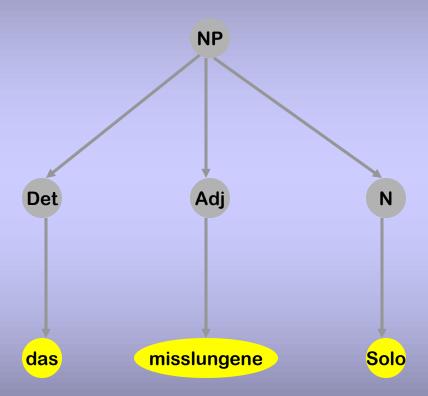
#### **Kein Schnitt**



### Grundbegriffe zu Ableitungsbäumen

- Sei  $\Gamma$  = (  $\mathcal{K}$ ,  $\rho$ , <\*, f) ein vollständig geordneter, markierter Baum mit  $f: \mathcal{K} \to \mathcal{M}$ . Eine Zeichenfolge  $m_1 m_2 ... m_n \in \mathcal{M}$  heißt Schnittbild in  $\Gamma$ , wenn es einen Schnitt {c<sub>1</sub>, c<sub>2</sub>, ..., c<sub>n</sub>} in  $\Gamma$  gibt mit
  - $c_1 < c_2 < ... < c_{n-1} < c_n$  und
  - f (c<sub>i</sub>) = m<sub>i</sub> für 1≤i ≤n.
- Falls der zugrundeliegende Schnitt mit der Menge der Endknoten identisch ist, heißt das Schnittbild auch Endschnittbild.

#### (End)Schnitt(Bild)

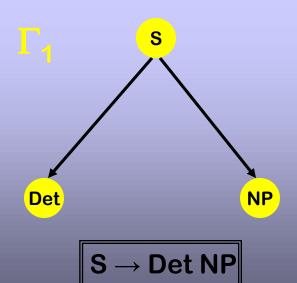


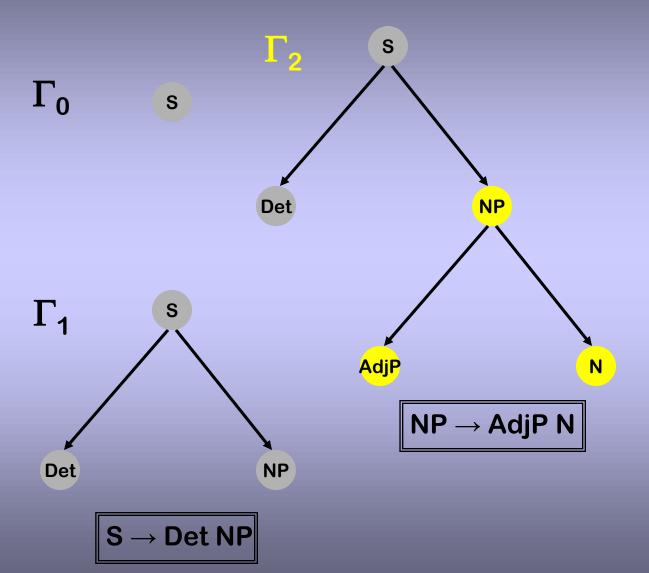
# Grundbegriffe zu Ableitungsbäumen

 Ein vollständig geordneter, markierter Baum  $\Gamma_n = (\mathcal{K}, \rho, <^*, f)$  heißt Ableitungsbaum (bzw. Strukturbaum) einer Ableitung  $\Delta = \{ \delta_i \}_{i=1}^n$  mit  $Q(\Delta) \in \mathbb{N}$  (bzw.  $Q(\Delta) = S$ ), wenn es ausgehend vom initialen Baum  $\Gamma_0$  (bestehend aus dem mit  $Q(\Delta)$  markierten Knoten) für jeden Ableitungsschritt  $\delta_i$ , 0≤i<n, eine korrespondierende Erweiterung im Sinne des Ableitungsbaums  $\Gamma_i$ gibt, dessen Endschnittbild  $\mathcal{Z}(\delta_{i+1})$  ist.

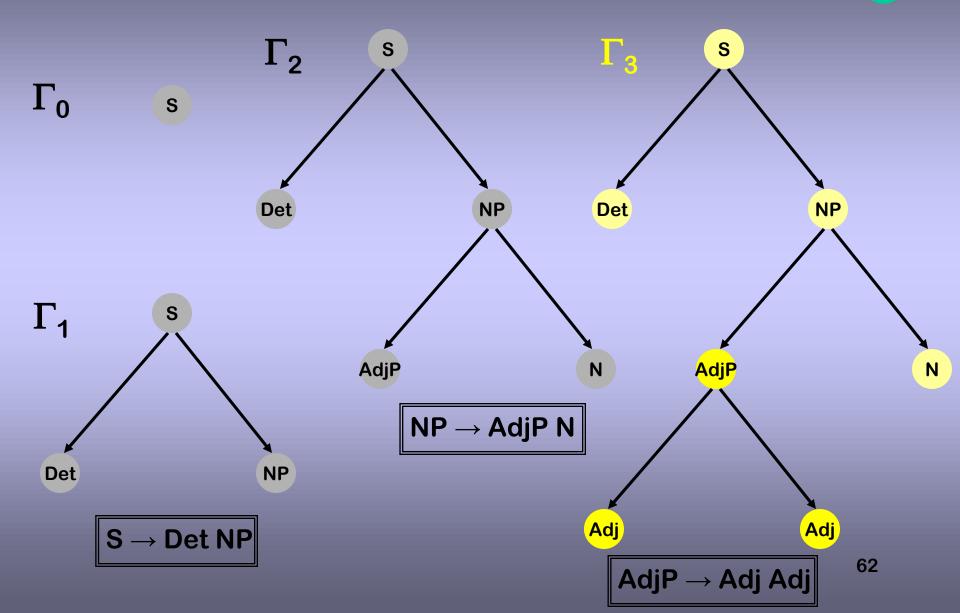
 $\Gamma_0$  s

 $\Gamma_0$  s





#### Strukturbaum einer Ableitung



# Grundbegriffe zu Ableitungsbäumen

- Sei  $\Delta = \{ \delta_i \}_{i=1}^n$  eine Ableitung in der Grammatik G mit  $\mathcal{Q}(\Delta) \in \mathbb{N}$ . Dann existiert genau ein Ableitungsbaum zu  $\Delta$ .
- Sei  $\Gamma$  ein Strukturbaum zur Grammatik G, also  $Q(\Delta)$  = S. Dann existieren im Allgemeinen mehrere verschiedene Ableitungen  $\Delta_1$  =  $\{\delta_{i1}\}_{i1=1}^n$ ,  $\Delta_2$  =  $\{\delta_{i2}\}_{i2=1}^m$ , ... zu  $\Gamma$ .

### Bemerkung zu Ableitungsbäumen

Bei jedem Erweiterungsschritt im jeweils vorliegenden Anfangsteilbaum  $\Gamma_{i}$  bestehen i.A. alternative Möglichkeiten für dessen Expansion, die letztlich zu alternativen Ableitungen führen. Die unterschiedliche Reihenfolge der Anwendung derselben Produktionen führt dennoch zum gleichen Strukturbaum.

Wählt man unter den mit einem Nichtterminalsymbol markierten Endknoten von  $\Gamma_{i}$  jeweils den am weitesten links bzw. rechts liegenden, erhält man eine durch den Strukturbaum eindeutig festgelegte Linksbzw. Rechtsableitung.

64

# Grundbegriffe zu Ableitungsbäumen

- Ableitungen, die denselben Strukturbaum haben, heißen äquivalent.
  - Zu jeder Ableitung  $\Delta = \{ \delta_i \}_{i=1}^n \text{ mit } \mathcal{Q}(\Delta) \in \mathbb{N}$  existiert genau eine äquivalente Links- bzw. Rechtsableitung.
- Jede Klasse von äquivalenten Ableitungen einer Satzform s heißt eine syntaktische Struktur von s. Sie kann durch einen Strukturbaum mit Endschnittbild s dargestellt werden.

## Grundbegriffe zu formalen Grammatiken

- Eine kontextfreie Grammatik G heißt eindeutig, wenn jedes Wort  $\omega \in \mathcal{L}(G)$  nur eine syntaktische Struktur besitzt.
- Eine Grammatik G, die nicht eindeutig ist, heißt mehrdeutig (ambig).

## Grundbegriffe zu formalen Grammatiken

- Sei die Grammatik G eindeutig. Dann besitzt jede Satzform S, für die ein  $\omega \in T^*$  mit  $S^* \Rightarrow \omega$  existiert, genau eine Rechtsund genau eine Linksableitung.
- Sei die Grammatik G eindeutig und S eine Rechtssatzform mit  $S^* \Rightarrow \omega$  für ein  $\omega \in T^*$ . Dann ist der Henkel von S und der zugehörige Rechtsreduktionsschritt eindeutig bestimmt.